

Случайные составляющие коэффициентов регрессии

Модель :

$$y = \alpha + \beta x + u$$

x – неслучайная экзогенная переменная

Уравнение регрессии :

$$\hat{y} = a + bx$$

Коэффициенты регрессии – случайные величины

Теорема

$$b = \frac{Cov(x, y)}{Var(x)} = \beta + \frac{Cov(x, u)}{Var(x)}$$

Условия Гаусса-Маркова (предположения о случайном члене)

1. $E(u) = 0$

2. $Var(u)$ постоянна для всех наблюдений

3. $Cov(u_i, u_j) = 0 \quad i \neq j$

4. $Cov(x_i, u_i) = 0$

или $E(x_i, u_i) = 0$

и u распределено по нормальному закону

Несмещенность коэффициентов регрессии

1.

$$E(b) = \beta + E\left\{\frac{Cov(x, u)}{Var(x)}\right\}$$

И если x – неслучайная величина, то

$$E(b) = \beta$$

2.

$$E(a) = \alpha$$

Точность коэффициентов регрессии

Теоретические дисперсии оценок a и b

$$Var(a) = \frac{\sigma_u^2}{n} \left\{ 1 + \frac{\bar{x}^2}{Var(x)} \right\}$$

$$Var(b) = \frac{\sigma_u^2}{nVar(x)}$$

Выводы:

- a и b прямо пропорциональны дисперсии остаточного члена
- чем больше число наблюдений, тем меньше дисперсии
- чем больше дисперсия x , тем меньше дисперсии коэффициентов

Оценки стандартных отклонений коэффициентов

Термин «стандартная ошибка»

$$m_b = \sqrt{\frac{\sum (y - \hat{y}_x)^2 / (n - 2)}{\sum (x - \bar{x})^2}} = \sqrt{\frac{S^2}{\sum (x - \bar{x})^2}}$$

$$m_a = \sqrt{\frac{\sum (y - \hat{y}_x)^2}{n - 2} \cdot \frac{\sum x^2}{n \cdot \sum (x - \bar{x})^2}} = \sqrt{S^2 \cdot \frac{\sum x^2}{n \cdot \sum (x - \bar{x})^2}}$$

- Применение: 1) проверка существенности коэффициента регрессии
- 2) построение доверительных интервалов

Оценка существенности коэффициента регрессии и свободного члена

Фактическое значение t-критерия сравнивается с табличным значением при определенном уровне значимости α и числе степеней свободы (n-2)

$$t_b = \frac{b}{m_b}, \quad t_a = \frac{b}{m_a} \quad - \quad \text{фактические значения}$$

Теорема $t_b^2 = F$

Доказательство:

$$t_b^2 = \frac{b^2}{m_b^2} = b^2 / \frac{\sum (y - \hat{y}_x)^2 / (n - 2)}{\sum (x - \bar{x})^2}$$

Продолжение доказательства

$$\begin{aligned} &= \frac{b^2 \sum (x - \bar{x})^2}{\sum (y - \hat{y}_x)^2 / (n - 2)} = \frac{\sum (\hat{y}_x - \bar{y})^2}{\frac{\sum (y - \hat{y}_x)^2}{(n - 2)}} \\ &= \frac{D_{\text{факт}}}{D_{\text{ост}}} = F \end{aligned}$$

Дисперсионный анализ результатов регрессии

Источники вариации	Число степеней свободы	Сумма квадратов отклонений	Дисперсия на одну степень свободы	F-отношение	
				фактическое	табличное при $\alpha=0,05$
Общая	6	1 5 0 0 0	--	--	--
Объясненная	1	1 4 7 3 5	1 4 7 3 5	2 7 8	6 , 6 1
Остаточная	5	2 6 5	5 3	1	--

$$m_b = \sqrt{\frac{53}{10,857}} = 2,21$$

$$t_b = \frac{36,84}{2,21} = 16,67 > t_{табл} = 2,57$$

Значимость коэффициента корреляции

Стандартная ошибка коэффициента корреляции

$$m_r = \sqrt{\frac{1 - r^2}{n - 2}}$$

Фактическое значение t-критерия Стьюдента

$$t_r = \frac{r}{\sqrt{1 - r^2}} \cdot \sqrt{n - 2}$$

Теорема

$$t_r^2 = t_b^2 = F$$

Доказательство:

См. выражения для t_r и F .

Вывод: проверка гипотез о значимости коэффициента регрессии b и коэффициента корреляции r равносильна проверке гипотезы о существенности линейного уравнения в целом.

Доверительные интервалы параметров регрессии

Доверительный интервал для коэффициента регрессии

$$(b - t_{табл} * m_b, b + t_{табл} * m_b)$$

Доверительный интервал для свободного члена регрессии

$$(a - t_{табл} * m_a, a + t_{табл} * m_a)$$

Доверительный интервал для коэффициента корреляции

$$(r - t_{табл} * m_r, r + t_{табл} * m_r)$$

Интервалы прогноза по линейному уравнению регрессии

Точечный прогноз y_p дополняется интервальной оценкой прогнозного значения

$$\hat{y}_x - m_{\hat{y}_x} \leq y^* \leq \hat{y}_x + m_{\hat{y}_x}$$

Теорема

$$m_{\hat{y}_x} = S \cdot \sqrt{\frac{1}{n} + \frac{(x_k - \bar{x})^2}{\sum (x - \bar{x})^2}}$$

Доказательство.

$$\hat{y}_x = \bar{y} - b \cdot \bar{x} + b \cdot x = \bar{y} + b \cdot (x - \bar{x})$$

Тогда

$$m_{\hat{y}_x}^2 = m_{\bar{y}}^2 + m_b^2 (x - \bar{x})^2$$

т.к.

$$Var(\bar{y}) = \frac{\sigma^2}{n}, \text{ то}$$

$$m_{\bar{y}}^2 = \frac{S^2}{n}$$

и

$$m_b^2 = \frac{S^2}{\sum (x - \bar{x})^2} \Rightarrow$$

$$m_{\hat{y}_x}^2 = \frac{S^2}{n} + \frac{S^2}{\sum (x - \bar{x})^2} \cdot (x_k - \bar{x})^2 = S^2 \cdot \left(\frac{1}{n} + \frac{(x_k - \bar{x})^2}{\sum (x - \bar{x})^2} \right)$$

Доверительные границы для \hat{y}_x

$$(\hat{y}_{x_k} - t_\alpha \cdot m_{\hat{y}_x}, \hat{y}_{x_k} + t_\alpha \cdot m_{\hat{y}_x})$$

Средняя ошибка прогнозируемого индивидуального значения y составит

$$m_{\hat{y}(x_k)} = s \cdot \sqrt{1 + \frac{1}{n} + \frac{(x_p - \bar{x})^2}{\sum (x - \bar{x})^2}}$$